

# LG Aimers: 메뉴별 매출 수량 예측 AI 파이프라인

## 한 줄 소개

희소(Zero-Inflated) 데이터를 극복하기 위해 분류와 회귀를 분할한 **Two-Stage** 파이프라인으로 일일 메뉴 판매 수량을 정교하게 예측하는 앙상블 AI 모델

## 프로젝트 정보

- **유형:** 해커톤 프로젝트 (LG Aimers)
- **주제:** 영업장 내 메뉴별 매출 수량 예측
- **언어:** Python 3.10+

## 사용 기술

| 기술                                        | 용도                                                   |
|-------------------------------------------|------------------------------------------------------|
| LightGBM (LGBMClassifier / LGBMRegressor) | Two-Stage 파이프라인의 메인 트리 기반 앙상블 예측 (빠른 속도 및 정형 데이터 특화) |
| PyTorch                                   | LSTM, Transformer 기반 다변량 시계열 장단기 트렌드 학습 검증           |
| Pandas / Numpy                            | 결측치 처리, 7/14/28일 이동평균 파생변수 생성 및 데이터 핸들링              |
| Scikit-learn                              | MinMaxScaler, RobustScaler 스케일링 체인                   |
| ARIMA (statsmodels)                       | 주말/평일 변동성이 높은 핵심 식당(Top 5) 데이터 시계열 타당성 검사            |
| 정규표현식 (re)                                | 메뉴명 텍스트 NLP 노멀라이징 및 형태소 토큰화                          |

## 시스템 구조도

```
flowchart TD
    subgraph Step1["Step 1: 전처리 및 피처 엔지니어링"]
        A["기존 훈련 데이터"] --> B["메뉴명 텍스트 형태소 정규화"]
    end
```

```

NLP"]
    B --> C["Lag 피쳐 및 이동평균 7/14/28일 생성"]
    C --> D["주말 평일 및 휴일 지시자 확립"]
end

subgraph Step2["Step 2: 룰베이스 강제 할당 Post-processing"]
    D --> E["블랙리스트 매장 메뉴 필터링"]
    E --> F["zero_ratio 높은 데이터 0 강제 할당"]
end

subgraph Step3["Step 3: Two-Stage 핵심 예측 로직"]
    F --> G{"Stage 1: 이진 분류 LGBM"}
    G -->|0 예측 안팔림| H["예측값 0"]
    G -->|1 예측 팔림| I["Stage 2: 회귀 분석 LGBM"]
    I --> J["최종 예상 판매 수량 도출"]
end

subgraph Step4["Step 4: 앙상블 병합"]
    J --> K["LGBM + LSTM Ensemble"]
    H --> K
    K --> L["최종 Submission 산출"]
end

```

flowchart TD

```

ROOT(("🍔 LG Aimers\n기술 스택"))

```

```

ROOT --> EDA["📊 EDA & Feature Engineering"]

```

```

ROOT --> ML["🤖 머신러닝 (Two-Stage)"]

```

```

ROOT --> DL["🧠 딥러닝 시계열"]

```

```

ROOT --> RB["📏 Rule-Based 보정"]

```

```

EDA --> EDA1["Pandas / Numpy"]

```

```

EDA --> EDA2["정규표현식 (텍스트 정규화)"]

```

```

EDA --> EDA3["이동평균 (Lag 7,14,28)"]

```

```

ML --> ML1["LightGBM Classifier"]

```

```

ML --> ML2["LightGBM Regressor"]

```

```

ML --> ML3["Scikit-learn Scailing"]
ML --> ML4["Optimal Threshold = 0.50"]

DL --> DL1["PyTorch"]
DL --> DL2["Vanila LSTM Sequence"]
DL --> DL3["Transformer Attention"]
DL --> DL4["ARIMA 통계 검증"]

RB --> RB1["휴무일 / 단종 강제 0 처리"]
RB --> RB2["zero_ratio 사전 필터링"]

```

## 핵심 구현 요약

### Step 1. 시계열 및 텍스트 Feature Engineering

- **시간적 특성 반영:** 날짜 데이터를 기반으로 7일, 14일, 28일 이동평균(Rolling Mean)을 생성해 주 단위 시계열 패턴 확립
- **텍스트 정규화:** "아이스 아메리카노"와 "아메리카노(ICE)" 같이 혼재된 데이터를 정규 표현식으로 정제해 누락되는 패턴 사전 차단
- **주말/공휴일 특성:** EDA 단계에서 포레스트릿, 화담숲주막 등의 매장이 주말/평일 편차가 큰 것을 파악해 `Weekend-major` 피쳐 도출

### Step 2. Zero-Inflated 타파: Two-Stage 모델링

- 0(No Sales) 값이 기형적으로 많은 분포 특성상, 단일 회귀 진행 시 하향 평준화(오차 급증) 발생을 확인
- **LGBM Classifier (1단계):** 이 메뉴가 오늘 '팔릴 것인지(1)' '안 팔릴 것인지(0)'를 우선 이진 분류
- **LGBM Regressor (2단계):** 판매될 것으로 분류된(1) 표본들에 한정해 '몇 개가 팔릴지' 구체적 볼륨을 회귀 예측

### Step 3. 하드코딩 기반 Rule-Based 최적화 (도메인 지식 융합)

- 머신러닝의 예측적 추론을 뛰어넘는 '물리적 한계'(식당 휴무일, 단종, 시즌 아웃 등)를 차단하기 위해 룰베이스 도입
- 전체 데이터셋에서 `zero_ratio` 와 `mean196` 통계 데이터를 구축해 아예 판매될 가능성이 없는 데이터는 0으로 덮어쓰기

## Step 4. 베이스라인 병합 및 앙상블

- 트렌드 파악 및 **ARIMA** 평가 기준과 **PyTorch** 기반 **LSTM(Lookback=28, Predict=7)** 다변량 시계열 테스트를 거쳐 최적의 앙상블 병합

### 문제 해결 경험

| 문제                          | 원인                                           | 해결                                                    |
|-----------------------------|----------------------------------------------|-------------------------------------------------------|
| 단일 회귀의 Underfitting 및 과소 예측 | 메뉴 판매 이력에 0값이 비정상적으로 많음 (Zero-Inflated)      | 이진 분류 개입 후 회귀를 연계하는 <b>Two-Stage</b> 구조 도입            |
| 주말 및 공휴일의 판매량 예측 빗나감        | 요일별 매출 편차(AM/PM, 주말/평일)가 큰 코어 매장(포레스트릿 등) 존재 | 주말 편차가 높은 데이터를 식별하는 <b>Weekend-major</b> 피처 추가 생성     |
| 동일 메뉴의 과거 이력 이 매칭 안됨        | 데이터 내 메뉴명이 섞여 있음 ("아메리카노" vs "americano")    | 정규표현식(Regex)을 활용한 텍스트 하드클렌징 및 NLP 정규화 진행              |
| 단종된 메뉴에 대한 모델의 무의미한 예측      | 알고리즘은 단종 여부를 모르고 과거 패턴대로 예측 시도               | <b>sale_ratio</b> 를 산출하여 물리적 확률이 희박한 경우 0으로 Overwrite |

### 코드 진화 요약

EDA 분석:        단순 월별 통계 → Rolling (7/14/28) 이동평균 파생변수 생성 도입  
전처리:         단순 라벨 인코딩 → 메뉴명 Regex 자연어 정규화 구조 세팅  
모델링:         단일 LightGBM Regressor → Classifier 결합 (Two-Stage 로직) → Rule-based 포스트프로세싱 체인 확립