

1주차

한 줄 소개

TikTok에서 조회수 10만 이상의 한국어 인기 영상만 자동으로 선별하는 5단계 AI 데이터 파이프라인

github

<https://github.com/junyi04/madcamp-week1.git>

프로젝트 정보

- 유형: 개인 프로젝트
- 기간: 1주
- 언어: Python 3.10+

사용기술

기술	용도
Playwright	브라우저 자동화, TikTok API 네트워크 인터셉트
PyTorch	ResNet50 CNN 모델 기반 이미지 유사도 분석 (GPU 가속)
ResNet50 (Transfer Learning)	이미지 특징 벡터 추출 → 중복 썸네일 자동 탐지
Google Cloud Translation API	텍스트 언어 감지 (한국어 필터링)
scikit-learn	Cosine Similarity 벡터 유사도 연산
asyncio	비동기 크롤링 및 이미지 다운로드
Pillow	이미지 전처리 (리사이즈, 정규화)
JSONL	스트리밍 데이터 저장 포맷

시스템 구조도

```

flowchart TD
    subgraph Step1["🕷️ Step 1: 크롤링"]
        A["TikTok Discover 5개 카테고리"] --> B["Playwright  
네트워크 인터셉트"]
        B --> C["조회수 10만+ 필터링"]
    end

    subgraph Step2["🧠 Step 2: CNN 중복 제거"]
        D["ResNet50 Feature Extractor"] --> E["3-Pass TTA"]
        E --> F["Cosine Similarity 임계값 0.82"]
    end

    subgraph Step3["🌐 Step 3: NLP 필터링"]
        G["한글 정규표현식 사전 검사"] --> H["Google Cloud API  
언어 감지"]
        H --> I["이중 검증: 제목→닉네임 Fallback"]
    end

    subgraph Step4["🏆 Step 4-5: 랭킹 & 저장"]
        J["URL 기반 중복 봉쇄"] --> K["조회수 정렬 Top 10 선정"]
        K --> L["ID 리매핑 dance01~10"]
    end

    C --> D
    F --> G
    I --> J
    L --> M["📦 배포용 JSON + 썸네일"]

```

```

flowchart TD
    ROOT(("🔧 TikTok AI Pipeline\n기술 스택"))
    ROOT --> CR["🕷️ 크롤링"]
    ROOT --> AI["🧠 AI 중복 제거"]
    ROOT --> NLP["🌐 NLP 필터링"]
    ROOT --> DM["📦 데이터 관리"]

```

```

CR --> CR1["Playwright"]
CR --> CR2["asyncio"]
CR --> CR3["Network Interception"]
CR --> CR4["봇 탐지 우회"]

AI --> AI1["PyTorch"]
AI --> AI2["ResNet50"]
AI --> AI3["Transfer Learning"]
AI --> AI4["3-Pass TTA"]
AI --> AI5["Cosine Similarity"]
AI --> AI6["GPU 가속"]

NLP --> NLP1["Google Cloud Translation API"]
NLP --> NLP2["정규표현식"]
NLP --> NLP3["langid 오프라인 대안"]

DM --> DM1["URL HashMap 중복제거"]
DM --> DM2["ID 리매핑"]
DM --> DM3["JSONL 스트리밍 저장"]
DM --> DM4["3일 Retention 자동삭제"]

```

핵심 구현 요약

1. 크롤링 (Playwright)

- Playwright의 `page.on("response")` 로 TikTok 내부 API JSON 응답을 직접 가로 채기
- Chrome 로그인 세션 유지 + `AutomationControlled` 비활성화로 봇 탐지 우회
- 5개 카테고리 × 5회 새로고침 × 15회 스크롤로 대량 데이터 수집
- `asyncio.to\_thread()`로 이미지 다운로드를 비동기 처리

2. CNN 중복 제거 (PyTorch + ResNet50)

- ResNet50의 FC Layer를 제거하여 **2,048차원 특징 벡터 추출기**로 변환 (Transfer Learning)
- 한 이미지를 3가지 시점(Center Crop / Full View / Zoom)으로 분석하는 ****TTA**** 적용
- L2 정규화 후 행렬곱으로 **Cosine Similarity** 계산, 임계값 0.82 이상이면 중복 판정

- GPU 배치 처리 + `torch.no\_grad()`로 메모리 최적화

3. NLP 필터링 (Google Cloud API)

- 한글 정규표현식으로 사전 필터 → ****API 호출 60% 절감**** (비용 최적화)
- 제목이 비어있으면 닉네임으로 2차 판별하는 **이중 검증 로직**
- API 장애 시 한글 글자 수 기반 폴백 + langid 오프라인 대안 준비

4-5. 랭킹 & 수명주기

- URL을 Key로 한 **HashMap**으로 동일 영상 중복 원천 봉쇄 (O(1))
- `dance01` ~ `dance10` 형태의 **ID 리매핑**으로 앱 서비스 연동 최적화
- 잔여 데이터 3일 보관 후 자동 삭제하는 **Retention Policy**

문제 해결 경험

문제	원인	해결
변형된 재업로드 영상 탐지 불가	MD5 해시는 1px만 달라도 다른 값	CNN 특징 벡터 기반 유사도 비교로 전환
이모지/무제목 한국 영상 유실	제목만으로 언어 판별 시 빈 제목 대응 불가	닉네임 Fallback 이중 검증 로직 추가
API 비용 폭증 우려	모든 데이터를 Google API에 전송	한글 정규표현식 사전 필터로 호출량 60% 절감
GPU OOM 크래시	3-Pass TTA로 메모리 사용량 3배 증가	배치 사이즈 512→256 조정 + 벤치마크 도구 개발
동일 영상 Top 10 중복 노출	같은 영상이 다른 조회수로 여러 번 수집	URL HashMap으로 1개만 보존 (최고 조회수)

코드 진화 요약

크롤러: 단일 카테고리 → 이미지 다운로드 추가 → 5개 카테고리 자동화 → 100K 필터 도입

CNN: 1-Pass 분석 → JSON 동기화 추가 → 3-Pass TTA + 격리소 패턴 도입

랭킹: 단순 정렬 → URL HashMap 중복 봉쇄 + Retention 자동 삭제